



Comparación entre regresión logística y modelos aditivos generalizados en datos binarios desbalanceados con predictores no lineales

Elaborado por:

Tatiana Marcela Gonzalez Cuadrado

Director:

Victor Hugo Morales Ospina

UNIVERSIDAD DE CÓRDOBA

DEPARTAMENTO DE MATEMÁTICAS Y ESTADÍSTICA

Programa de estadística

Montería, 2026

Agradecimientos

Primeramente, agradezco a Dios por permitirme llegar hasta este momento tan significativo de mi vida. Por brindarme la fortaleza, la disciplina y el discernimiento necesarios para culminar este trabajo.

Extiendo mi gratitud al Dr. Víctor Hugo Morales Ospina, por su acompañamiento a lo largo de este proceso, por sus valiosas correcciones y su orientación constante.

A mis padres, Carlos y Sandra, les expreso mi más profundo agradecimiento por su apoyo, su amor y su acompañamiento en cada etapa de este proceso. A mis hermanas, Dayana y Giuliana, y a mi abuela María Inés, por ser una fuente constante de motivación y cariño, así como a toda mi familia, que ha sido siempre un refugio en los momentos más desafiantes.

A mis amigos Víctor, Jorge, Edwin y a todos aquellos compañeros que me ha dejado esta carrera, gracias por compartir este camino y por cada experiencia vivida. De manera especial, agradezco a mi mejor amiga Rosanny María, por su incondicionalidad

Índice

1. Introducción	6
2. Estado Del Arte	7
3. Marco Teórico	13
3.1. Variables binarias y definición del modelo de regresión logística	13
3.2. Estimación de parámetros del modelo de regresión logística	14
3.3. Modelos lineales generalizados	15
3.4. Modelos aditivos generalizados	15
3.4.1. Penalización	16
3.4.2. Selección de suavidad	17
3.4.3. Grados efectivos de libertad	17
3.4.4. Estimación	17
3.5. Desbalance de clases en datos binarios	17
3.6. No linealidad en las covariables	18
3.7. Proceso de simulaciones	18
3.8. Métricas de evaluación	21
4. Metodología	24
4.1. Tipo y diseño de investigación	24
4.2. Población	26
4.3. Tipo de muestreo	26
4.4. Variables	26
5. Resultados	27
5.1. Análisis de la variable edad	27
5.2. Análisis de la variable sede	28

5.3. Análisis de la variable IMC	29
5.4. Análisis de la variable discapacidad determinada por la edad	31
5.5. Análisis de los resultados de los datos reales	31
5.6. Análisis de los resultados de las simulaciones	33
5.6.1. Resultados de las métricas de desempeño en la relación lineal	33
5.6.2. Resultados de las métricas de desempeño en las relaciones NO lineales	33
6. Resultados y conclusiones	35
7. Anexos	37
8. Referencias	47

Índice de cuadros

1.	Variables de interés en el estudio	26
2.	Medidas descriptivas de la variable Edad	28
3.	Percentiles de la variable Edad	28
4.	Medidas descriptivas de la variable IMC	30
5.	Percentiles de la variable IMC	30
6.	Estimaciones del modelo logístico en la base de datos real	32
7.	Estimaciones del GAM en la base de datos real	32
8.	Comparación de modelos ajustados a la base de datos real	32
9.	Prueba t, muestras pareadas en modelos con datos reales	32
10.	Categorías de la variable sede	37
11.	Métricas de desempeño de modelo logístico: Componente LINEAL	38
12.	Métricas de desempeño de GAM: Componente LINEAL	39
13.	Métricas de desempeño de modelo logístico: Componente NO LINEAL DÉBIL	40
14.	Métricas de desempeño de GAM: Componente NO LINEAL DÉBIL	41
15.	Métricas de desempeño de modelo logístico: Componente NO LINEAL SUAVE	42
16.	Métricas de desempeño de GAM: componente NO LINEAL SUAVE	43
17.	Métricas de desempeño de modelo logístico: Componente NO LINEAL FUERTE	44
18.	Métricas de desempeño de GAM: Componente NO LINEAL FUERTE	45

Índice de figuras

1.	Función Logística	14
2.	Distribución de la variable edad	27
3.	Distribución de la variable sede	28
4.	Distribución de la variable IMC	29
5.	Boxplot de la variable IMC	30
6.	Distribución de la variable discapacidad determinada por la edad	31
7.	Función suave para la variable Edad	45
8.	Función suave para la variable IMC	46

1. Introducción

De acuerdo con la Organización Panamericana de la Salud (Organización Panamericana de la Salud, 2023), las personas con discapacidad son aquellas que presentan deficiencias físicas, mentales, intelectuales o sensoriales a largo plazo que, en interacción con diversas barreras, pueden limitar su participación plena y efectiva en la sociedad en igualdad de condiciones con los demás. Asimismo, el Informe Mundial sobre la Discapacidad (Organización Mundial de la Salud & Banco Mundial, 2011) señala que alrededor del 15 % de la población mundial vive con algún tipo de discapacidad. Se ha evidenciado que las mujeres presentan mayor probabilidad de padecer discapacidad en comparación con los hombres, y que esta condición es más frecuente en personas mayores que en jóvenes. En América Latina y el Caribe, se estima que cerca del 12 % de la población vive con al menos una discapacidad, lo que equivale aproximadamente a 66 millones de personas. Este panorama pone de manifiesto la relevancia social y sanitaria de estudiar los factores asociados a la discapacidad.

Bajo esta perspectiva, el modelamiento de variables respuesta binarias constituye un problema recurrente en áreas como la estadística aplicada, la epidemiología y las ciencias sociales. Tradicionalmente, la regresión logística ha sido una de las herramientas más utilizadas debido a su interpretabilidad y a su sólida fundamentación teórica (Martínez Pérez & Pérez Martín, 2024). Sin embargo, en aplicaciones reales es frecuente encontrar dos dificultades importantes: la presencia de desbalance severo entre las clases y relaciones no lineales entre las covariables y la respuesta. Estas condiciones pueden afectar significativamente el desempeño de los modelos logísticos clásicos, lo que ha motivado el uso de enfoques más flexibles, como los modelos aditivos generalizados (GAM), que permiten capturar patrones no lineales sin imponer una forma funcional específica (Aguilar Barreiro, 2019). En este trabajo, emplearemos las técnicas estadísticas mencionadas para modelar la probabilidad de presentar discapacidad en base a dos variables continuas y una categoría asociada a la sede.

De esta manera, a lo largo de la literatura se ha abordado tanto el problema del desbalance en variables binarias como la presencia de relaciones no lineales, tal como lo evidencian (Chiabudini

et al., 2020) y (Cho et al., 2022). Sin embargo, la literatura que aborda simultáneamente desbalance de clases y no linealidad en modelos binarios aún es limitada, al igual que el efecto de ellos en distintos ámbitos o escenarios. Por esta razón, el presente trabajo propone comparar el desempeño de la regresión logística tradicional y los modelos aditivos generalizados bajo diferentes escenarios que involucren desbalance de clases y no linealidad, utilizando un enfoque de simulación. Además, se emplearán estas técnicas para modelar la probabilidad de presentar discapacidad a partir de dos variables continuas y una variable categórica asociada a la sede, de igual manera, la relación en un contexto de datos real.

2. Estado Del Arte

A partir de datos transversales correspondientes a 23694 adultos mayores de 60 años de la encuesta SABE Colombia (Gómez et al., 2021), se analizaron los determinantes estructurales e intermedios del envejecimiento asociados a la discapacidad en Colombia mediante un modelo de regresión logística multivariante. El estudio consideró variables demográficas y socioeconómicas con el objetivo de identificar los principales factores asociados a la discapacidad en la población adulta mayor. Los resultados evidenciaron una prevalencia del 21 % en discapacidad para actividades básicas de la vida diaria, 38 % para actividades instrumentales y 33 % para discapacidad de movilidad. Así mismo, se encontraron asociaciones significativas con determinantes sociodemográficos como edad avanzada, sexo femenino, residencia rural, nunca casado/divorciado, vivir solo, bajo nivel educativo y pertenencia étnica indígena/Negra. Estos hallazgos manifiestan el carácter multifactorial de la discapacidad y resaltan la necesidad de abordarla desde una perspectiva integral, aspecto que resulta particularmente relevante para el presente estudio, además refuerza la importancia de considerar múltiples covariables estructurales y sociales en el modelamiento estadístico de la discapacidad.

Haciendo énfasis en la importancia de analizar factores asociados a la discapacidad en Colombia, se tomó el total de registros de personas con discapacidad de origen vial en Medellín (López, 2022)

y se desarrollaron cuatro modelos de regresión logística para identificar factores asociados con dependencia funcional, participación familiar, académica y laboral. Como resultado se encontró que entre 2004-2017 Medellín tenía registradas 63.848 personas con discapacidad. La causa que más la generó fue la enfermedad general con 21.444, es decir, el 33,3 % de los registros y los incidentes viales ocuparon el primer lugar entre las incidentales con 3.092 que corresponde al 39,3 %. Lo anterior evidencia la relevancia de estos datos y el uso de modelos estadísticos para analizar los factores que se asocian a la discapacidad.

En Colombia se han desarrollado estudios comparativos entre distintos enfoques de modelamiento estadístico aplicado a variables binarias. Por ejemplo, (Salazar et al., [2012](#)) compararon regresión logística con máquinas de vectores de soporte (SVM) para tareas de discriminación binaria, evaluando cuál método mostraba mejor capacidad de clasificación en un conjunto de datos reales dentro del contexto colombiano. Este tipo de análisis comparativo respalda metodológicamente la relevancia de evaluar múltiples modelos mediante criterios de desempeño, especialmente cuando se enfrentan problemas con características complejas como la no linealidad o el desbalance de clases como lo es el caso de la discapacidad.

De acuerdo con (López, [2022](#)), quien analizó factores de riesgo asociados al bajo peso al nacer en Medellín aplicando modelos de regresión logística clásica, regresión penalizada y modelos aditivos generalizados (GAM), enfrentando el desbalance de datos proporcionados, permitiendo mejorar la detección de datos críticos, logrando modelos más flexibles y precisos. En sus resultado se identificó que, comunas como Manrique, Popular y Robledo concentran la mayor incidencia de casos, y que la talla al nacer y las semanas de gestación son factores clave asociados al riesgo. En este contexto se observa que, ante datos clínicos reales y complejos, el uso de métodos modernos combinados con enfoques clásicos aporta resultados más robustos para el modelamiento de datos de salud pública. Esto demuestra que es óptimo considerar alternativas a los modelos tradicionales para contrarrestar los efectos del desbalance de clases y la no linealidad que se puedan presentar en algunos tipos de datos.

En un contexto clínico al exterior de Colombia, el modelo logístico permitió diferenciar claramente

qué factores influyen en cada dimensión (síntomas vs. discapacidad), mostrando que no son los mismos para ambos aspectos (Ganev, [2000](#)). Este artículo es relevante porque utiliza **Modelos Logísticos** para identificar los factores clínicos que predicen la evolución de los síntomas psicóticos y la discapacidad social en pacientes con esquizofrenia. Los resultados muestran que los síntomas y la discapacidad social siguen trayectorias relativamente independientes, y que la discapacidad social tiende a deteriorarse en muchos casos, incluso cuando los síntomas mejoran. El modelo logístico permitió destacar variables como la historia familiar de enfermedad mental y el tipo de inicio de la enfermedad para los síntomas, y factores como el género, la edad de inicio, y los “activos de personalidad” para la discapacidad. Esto subraya la importancia de considerar la discapacidad social como un aspecto central y autónomo en el estudio de la esquizofrenia, ya que afecta directamente la calidad de vida y el pronóstico a largo plazo.

(Austin et al., [2010](#)) comparó los modelos de regresión, modelos de regresión logística y modelos GAM para ajustar cuatro variables continuas: edad, presión arterial sistólica, frecuencia respiratoria y BUN, que son variables que están directamente relacionadas con la mortalidad hospitalaria en pacientes hospitalizados con insuficiencia cardíaca, para modelar como efectos lineales en el modelo de predicción de mortalidad EFFECT-HF utilizando splines de suavizado, cada una con cinco grados de libertad y las variables dicotómicas restantes se trataron como tales para el modelo GAM. Así mismo, se modelaron las variables con los demás casos y se evidenció que la regresión logística tiene un desempeño superior para predecir la mortalidad hospitalaria en pacientes con insuficiencia cardíaca ya que puede explicar las relaciones lineales subyacentes entre las covariables continuas y las probabilidades logarítmicas de la mortalidad hospitalaria. Esta conclusión resulta clave a tener en cuenta ya que en este caso se usó la teoría que se utilizará oportunamente en este trabajo para llevar a cabo nuestros objetivos, recalcando que los resultados dependen de los tipos de datos a utilizar y sus condiciones ya que como se logra evidenciar, las variables resultaron tener un efecto lineal entre ellas, por lo que era de esperarse que el modelo logístico tuviera mejor desempeño al ajustar los datos. Con base en un análisis comparativo de modelos aditivos generalizados para la predicción del riesgo de obesidad (Awe et al., [2025](#)) demostraron la flexi-

bilidad de los modelos aditivos generalizados para modelar datos de obesidad, lo que refuerza la idea de que los métodos convencionales pasan por alto las asociaciones no lineales y los efectos de interacción entre predictores demográficos, socioeconómicos y conductuales, que son especialmente importantes en poblaciones diversas con diversos determinantes de la obesidad. Se tiene en cuenta que los modelos de regresión supervisada, incluyendo la regresión lineal y logística, han sido ampliamente utilizados en la investigación de la obesidad para predecir resultados basados en factores demográficos, conductuales y genéticos. Sin embargo, estos modelos a menudo se basan en supuestos restrictivos, como relaciones lineales o monótonas entre predictores y resultados, y propiedades distribucionales específicas de la variable de respuesta que lleva a estimaciones sesgadas y una precisión predictiva reducida, particularmente en poblaciones heterogéneas. De esta manera, estos modelos, en especial el GAMLSS (Modelos aditivos generalizados para ubicación, escala y forma) les permitió modelar diversas características distributivas como la asimetría y la curtosis, resultados valiosos para identificar patrones sutiles y no lineales en los datos de obesidad que los modelos tradicionales pueden pasar por alto, lo que conlleva a un aporte importante en el objetivo de esta investigación donde buscamos alternativas para modelar una estructura de datos que no cumple con los criterios usuales que garantizan un adecuado desempeño de los modelos de regresión logística y de regresión clásica limitando la validez de dichos enfoques en este contexto. Así mismo, de la enfermedad del Alzheimer(EA) (Muchlinski et al., [2019](#)) se tomó un artículo llamado metodología estadística para clasificaciones multiclase: aplicaciones a la demencia, en el que se presenta el modelado de las personas sin deterioro cognitivo y/o deterioro cognitivo leve y demencia, donde se destaca la importancia de los esfuerzos para identificar las etapas presintomáticas de la EA y los biomarcadores que la clasifiquen. En el estudio, se adaptó un modelo de regresión logística aditiva al contexto de la enfermedad con múltiples categorías ordenadas. Con este enfoque, se seleccionó y combinó múltiples biomarcadores transversales para mejorar la precisión diagnóstica, además de evaluar la robustez del modelo propuesto mediante un estudio de simulación. De esta manera, entre los hallazgos se tiene que el método propuesto puede utilizarse para identificar biomarcadores que reflejen la patología subyacente, en la que las categorías de

patología serán la variable de resultado de un modelo de regresión logística ordinal aditiva (ALR), que es una variante del modelo aditivo generalizado. Este modelo proporciona un método flexible para identificar y caracterizar el efecto de la regresión no lineal de los predictores. Esta alternativa resulta significativa ya que utiliza un caso particular de los modelos aditivos generalizados para afrontar el supuesto de no linealidad de los datos clínicos.

Por esa misma línea, un estudio que se enfoca en la comparación de estrategias de modelado complejas para la predicción de un resultado binario basado en unos pocos predictores altamente correlacionados (Chiabudini et al., [2020](#)) aborda puntos importantes y de enfoques puntuales motivado por un problema de predicción clínica, donde se realizó un estudio de simulación para comparar diferentes enfoques para la construcción de modelos de predicción de riesgo donde se pretendía obtener modelos robustos de predicción de supervivencia hospitalaria en pacientes con insuficiencia cardíaca aguda a partir de tres parámetros sanguíneos altamente correlacionados, medidos hasta cuatro veces, priorizando explícitamente la capacidad predictiva sobre la interpretabilidad. Principalmente se investigaron diferentes versiones penalizadas de regresión logística, así como bosques aleatorios y modelos aditivos generalizados utilizando la regresión logística clásica como referencia. Su rendimiento se evaluó con base en medidas de precisión predictiva, discriminación y calibración de cada modelo. Entre sus aportes más importantes es necesario destacar que además de los métodos de regresión penalizados utilizados, los GAM que se incluyeron como técnicas candidatas sirvió como un método flexible que permitió formas funcionales de los predictores diferentes de ser exclusivamente lineales, proporcionando así una alternativa a la inclusión de transformaciones preespecificadas de variables en el conjunto de predictores. Concluyendo así que, comparando todas las simulaciones se habría proporcionado la base para elegir una estrategia de modelado entre los modelos de referencia considerados, seleccionando la mejor estrategia para aquellos modelos más realistas, a modo de estimación fundamentada. Lo que se busca en este trabajo evaluando mediante un estudio de simulación, el desempeño de diferentes estrategias estadísticas bajo escenarios previamente definidos.

(Yeganeh et al., [2023](#)) realizaron un estudio donde se busca monitorizar la estabilidad de la relación

entre los tipos de ictus y las variables explicativas predefinidas a lo largo del tiempo dentro de este conjunto de datos. Los amplios resultados de simulación, basados en datos reales de pacientes con ictus agudo, demuestran la notable flexibilidad de los modelos GAM en cuanto a su capacidad de detección en comparación con los enfoques convencionales. Esto se logra no solo usando modelos aditivos generalizados, si no también otro tipo de métodos estadísticos que lo respalden, en este caso se hace uso, como enfoque avanzado, los gráficos de control, que se consideran parte del área de Monitoreo Estadístico de Procesos (SPM) demostrando una vez más que es necesario no solo evaluar un tipo de modelo en variables respuestas binarias ya que el resultado de estas, no dependen de un solo factor. Supuesto que es esencial en el desarrollo de este trabajo.

Haciendo una síntesis de información desde el contexto nacional hasta el contexto internacional, se logra evidenciar un avance en los factores que se asocian a la discapacidad y el uso de modelos estadísticos para variables binarias. Sin embargo, logramos identificar que la mayoría de estos estudios se centran en aplicaciones de un contexto específico de aplicaciones reales donde se prioriza la interpretación superficial y las comparaciones metodológicas bajo supuestos controlados, sin abordar simultáneamente problemáticas comunes en un contexto real como el desbalance de clases y la presencia de relaciones no lineales entre predictores y la variable respuesta. Aunque en varios trabajos se hace uso de modelos aditivos generalizados (GAM) y técnicas penalizadas, aún es limitada la evidencia sobre su desempeño comparativo frente a la regresión logística en escenarios simulados que integren simultáneamente estas condiciones complejas. En este sentido, se logra identificar una brecha en la evaluación de modelos bajo estructuras de datos que no necesariamente garantizan resultados robustos. Por lo tanto, el presente estudio busca contribuir a esta brecha mediante un análisis comparativo entre la regresión logística y los modelos aditivos generalizados en datos binarios desbalanceados con predictores no lineales, utilizando un enfoque de simulación que permita establecer criterios más sólidos para la selección de modelos en contextos aplicados de salud pública.

3. Marco Teórico

3.1. Variables binarias y definición del modelo de regresión logística

De acuerdo con (Agresti, 2002) la regresión logística es uno de los métodos más utilizados en los procesos de estimación gracias a la robustez de los resultados en variables binarias. Este modelo hace parte de los modelos lineales generalizados y se caracteriza por explicar la probabilidad de ocurrencia de un evento ante la no ocurrencia de este, modelando los dos tipos de variables existentes: Cualitativas y cuantitativas.

Este modelo es ampliamente utilizado en muchos ámbitos del conocimiento desde el médico por su óptimo reconocimiento en factores de riesgo, hasta sectores más alejados como las ciencias sociales para el modelamiento de decisiones binarias. Las variables respuesta binarias se caracterizan por tomar dos posibles valores, usualmente codificados como cero y uno, y aparecen con frecuencia en estudios de distintas áreas del conocimiento. De manera ampliada, los modelos de regresión logística tienen como objetivo el modelamiento de la relación entre una variable respuesta Y de carácter dicotómica y un conjunto de covariables X_i , permitiendo identificar los efectos de los diferentes factores (Giolo, 2017).

Sea Y una variable aleatoria Bernoulli tal que $Y \in \{0, 1\}$, con $P(Y = 1) = \pi$. La regresión logística constituye el enfoque clásico para modelar este tipo de respuestas, relacionando la probabilidad π con un conjunto de covariables $\mathbf{X} = (X_1, \dots, X_p)^T$ mediante la función de enlace logit

$$\log \left(\frac{\pi}{1 - \pi} \right) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p. \quad (1)$$


Donde $x_1, x_2, \dots, x_p$ es un vector de mediciones continuas correspondiente a covariables y variables ficticias correspondientes a niveles de factores, y $\beta_1, \beta_2, \dots, \beta_p$ es el vector de parámetros.

La función logística que da lugar al modelo, se define de la siguiente manera,

$$f(x) = \frac{1}{1 + e^{-x}}, x \in R \quad (2)$$

Así mismo, se representa como

Figura 1: Función Logística



Fuente: Tomado de López, 2022.

En la Figura 1 se representa la función logística, la cual transforma el predictor lineal —definido como una combinación de las variables explicativas— en una probabilidad contenida en el intervalo $(0, 1)$ para la variable respuesta Y .

3.2. Estimación de parámetros del modelo de regresión logística

Específicamente en este trabajo, usaremos entre las diferentes maneras de estimar parámetros y de acuerdo con (Montgomery et al., 2002) quien considera que la mejor manera de estimar parámetros es por medio de la estimación de máxima verosimilitud en comparación con otras estrategias, además de ser la forma que el software R-Studio utiliza por defecto. En términos generales, la estimación de máxima verosimilitud tiene como objetivo maximizar la probabilidad de obtener el conjunto de datos observados (Montgomery et al., 2002), (Giolo, 2017). Tomando como referencia a (Montgomery et al., 2002), consideramos que el método de máxima verosimilitud de un modelo logístico se define conociendo los estimadores resultantes $\hat{\alpha}, \hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_n$, de tal manera que, el valor esperado del modelo de regresión logística se escribe como:

$$E(Y_i) = \pi_i = \frac{1}{1 + \exp(-\eta_i)} \quad (3)$$

donde,

$$\eta_i = \sum_{j=1}^p \beta_j x_{ij}, \quad j = 1, \dots, p. \quad (4)$$

3.3. Modelos lineales generalizados

Los modelos lineales generalizados (GLM) surgen como una extensión del modelo lineal clásico con el objetivo de permitir el análisis de variables respuesta que no siguen una distribución normal. De acuerdo con (Dobson, 2002), un GLM se compone de tres elementos fundamentales: una distribución de probabilidad perteneciente a la familia exponencial para la variable respuesta, un predictor lineal que combina las covariables mediante una relación lineal en los parámetros, y una función de enlace que relaciona la media de la variable respuesta con dicho predictor. Dentro de estos modelos, la regresión logística constituye un caso particular ampliamente utilizado cuando la variable respuesta es binaria. En este caso, se asume que la variable sigue una distribución Bernoulli y se emplea la función de enlace logit para modelar la probabilidad de ocurrencia del evento de interés en función de un conjunto de covariables. Este enfoque resulta atractivo por su facilidad de interpretación y por su sólida fundamentación teórica; sin embargo, descansa sobre el supuesto de que existe una relación lineal entre las covariables y el logit de la probabilidad, lo cual no siempre se cumple en aplicaciones reales (McCullagh & Nelder, 1989). Con el propósito de considerar la restricción de linealidad presente en los GLM tradicionales, se introducen los Modelos aditivos generalizados.

3.4. Modelos aditivos generalizados

Los modelos aditivos generalizados (GAM) mantienen la estructura probabilística de los GLM tradicionales, pero permiten que la relación entre la variable respuesta y las covariables sea más flexible donde en lugar de asumir una relación lineal estricta, los GAM modelan el predictor como una suma de funciones suaves de las covariables estimadas a partir de los datos. En términos generales, se expresan como:

$$g(E[Y | \mathbf{X}]) = \beta_0 + f_1(x_1) + \cdots + f_p(x_p) \quad (5)$$

donde $g(\cdot)$ es la función de enlace y $f_j(\cdot)$ representan funciones suaves que capturan posibles relaciones no lineales. En el caso de una variable respuesta binaria, el uso del enlace logit da lugar a un modelo que generaliza la regresión logística clásica, permitiendo identificar patrones no lineales entre las covariables y la probabilidad del evento de interés. Esta flexibilidad convierte a los GAM en una alternativa adecuada cuando los supuestos de linealidad del modelo logístico estándar no se cumplen (Hastie & Tibshirani, 1990).

Por medio de Rstudio, cada función suave se aproxima mediante una combinación de funciones base:

$$f(x) = \sum_{k=1}^K \beta_k B_k(x)$$

donde $B_k(x)$ son bases tipo *thin plate regression splines*, utilizadas por defecto en `mgcv` (Wood, 2017).

3.4.1. Penalización

El modelo se estima mediante verosimilitud penalizada:

$$\ell_p = \ell(\beta) - \lambda \beta^T S \beta$$

equivalentemente:

$$\text{Deviance} + \lambda \int (f''(x))^2 dx$$

donde λ controla el nivel de suavidad.

3.4.2. Selección de suavidad

El parámetro λ se estima automáticamente mediante criterios como REML o GCV, equilibrando ajuste y suavidad.

3.4.3. Grados efectivos de libertad

La complejidad del modelo se mide mediante los grados efectivos de libertad:

$$\text{EDF} = \text{tr}(S_\lambda)$$

Valores cercanos a 1 indican relaciones lineales, mientras que valores mayores indican no linealidad.

3.4.4. Estimación

El modelo se ajusta mediante el método de mínimos cuadrados ponderados penalizados:

$$(X^T W X + \lambda S) \beta = X^T W z$$

lo cual se resuelve iterativamente mediante *Penalized Iteratively Reweighted Least Squares (PIRLS)*.

3.5. Desbalance de clases en datos binarios

De acuerdo con la teoría de modelos lineales generalizados (McCullagh & Nelder, 1989), el desbalance de clases ocurre cuando una de las categorías de la variable respuesta es considerablemente menos frecuente que la otra, situación común en problemas de detección de eventos raros. Este fenómeno puede afectar la estimación de los parámetros del modelo y deteriorar el desempeño predictivo, especialmente en términos de sensibilidad para la clase minoritaria. En contextos de desbalance severo, los modelos tradicionales pueden presentar dificultades para identificar adecuadamente el evento de interés ya que tienden a sobreestimar la probabilidad de pertenencia a la clase

mayoritaria, lo que se concluye como una baja capacidad para identificar correctamente los casos de interés.

Adicionalmente, el uso de métricas globales como el *accuracy* puede resultar incorrecto ya que tiende a presentar valores elevados prediciendo solo la clase mayoritaria sin capturar adecuadamente la clase minoritaria. De igual manera, la elección de umbrales de clasificación estándar puede no ser adecuada en estos contextos, afectando el equilibrio entre sensibilidad y especificidad. Dejando en evidencia la necesidad de considerar enfoques metodológicos que permitan evaluar de manera más adecuada el desempeño del modelo y explorar alternativas que disminuyan los efectos del desbalance en la estimación y el pronóstico.

3.6. No linealidad en las covariables

En muchos problemas aplicados, la relación entre la variable respuesta y algunas covariables no sigue un patrón lineal, lo cual limita la capacidad de los modelos paramétricos para describir adecuadamente el fenómeno estudiado. En el contexto de la regresión logística, la no linealidad se manifiesta cuando la relación entre una covariable y el logit de la probabilidad no puede representarse adecuadamente mediante un término lineal. Ignorar este comportamiento puede conducir a estimaciones sesgadas y a una pérdida de capacidad predictiva, lo que justifica el uso de modelos que permitan relaciones funcionales más generales, es decir modelos más flexibles como lo son los modelos aditivos generalizados (Hastie & Tibshirani, 1990). En este sentido, estos modelos permiten sustituir el predictor tradicional por una suma de funciones suaves de las covariables estimadas.

3.7. Proceso de simulaciones

1. Se procede a generar los datos por medio de una distribución normal multivariada por medio de R-Studio, con la función **rmvnorm** definiendo media y desviación estándar tomadas como referencia de la base de datos real para la variable edad (68,12) e IMC (26,6) respectivamente. Así mismo, una variable sede, de carácter categórica con niveles $k = A, B$ y C

con probabilidades 0.4, 0.35 y 0.25 respectivamente. Estas, se distribuyen con probabilidad proporcional al tamaño de los tres niveles de referencia de la variable real SEDE presente en la base de datos “Servicios de Salud Norte del Distrito Capital de Bogotá D.C”. Así mismo, se define una matriz de covarianza de la siguiente manera:

$$\Sigma = \begin{pmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{pmatrix} = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix} = \begin{pmatrix} 168 & \rho(-14.44) \\ \rho(-14.44) & 31 \end{pmatrix} \quad (6)$$

2. Se definen los escenarios de las simulaciones, donde se tienen en cuenta diferentes tamaños de muestra, niveles de correlación y niveles de desbalance, condiciones que resultan indispensable para considerar los distintos modelos ya que el desempeño predictivo y la estabilidad de los estimadores dependerá de cada escenario (Woo et al., 2008). Adicionalmente, estos escenarios permiten evaluar la capacidad de los modelos para capturar diferentes estructuras funcionales discriminadas por las diferentes relaciones que se tendrán en cuenta en los procesos de simulación: Relación lineal y distintas relaciones no lineales. En este sentido, se definen los escenarios de la siguiente manera:

- a) Tamaños de muestras correspondientes a $n = 50, 100, 300, 600$ y 1000 .
- b) Nivel de correlación, $\rho = \{0.3, 0.8\}$
- c) Nivel de desbalance ajustando el intercepto β_0 , para lograr una proporción de eventos π predefinida, de tal manera que se cumpla

$$\pi \approx \frac{1}{n} \sum_{i=1}^n p_i = \frac{1}{n} \sum_{i=1}^n \frac{1}{1 - \exp(-\beta_0 + \eta_i)} \quad (7)$$

Donde $\pi \in \{0.05, 0.15, 0.5\}$. Obteniendo así

- Para el caso lineal donde η_i se define como

$$\eta_i = \beta_1 Edad_i + \beta_2 IMC_i + \alpha_{Sede_i} \quad (8)$$

$$\beta_0 \text{ tal que } \frac{1}{n} \sum_{i=1}^n \frac{1}{1 + \exp(-(\beta_0 + \beta_1 Edad_i + \beta_2 IMC_i + \alpha_{Sede_i}))} \approx \pi$$

- Para el caso no lineal donde el η_i se define como

$$\eta_i = f_1(Edad_{c,i}) + f_2(IMC_{c,i}) + \alpha_{Sede_i} \quad (9)$$

$$\beta_0 \text{ tal que } \frac{1}{n} \sum_{i=1}^n \frac{1}{1 + \exp(-(\beta_0 + f_1(Edad_{c,i}) + f_2(IMC_{c,i}) + \alpha_{Sede_i}))} \approx \pi$$

d) Casos de no linealidad y generadores de datos.

- Relación lineal 8.
- Relación no lineal donde se definen las variables edad e IMC de la siguiente manera para todos los casos:

$$Edad_c = Edad_i - \frac{1}{n} \sum_{i=1}^n Edad_i$$

$$IMC_c = IMC_i - \frac{1}{n} \sum_{i=1}^n IMC_i$$

Tomando en cada caso 9, donde f_1 y f_2 se definen para

- Relación no lineal débil donde es considerando un polinomio de segundo grado:

$$f_1(Edad_c) = 0.03 Edad_c - 0.0012 Edad_c^2$$

$$f_2(IMC_c) = 0.08 IMC_c - 0.015 IMC_c^2$$

- Relación no lineal suave donde es considerando un componente sinusoidal:

$$f_1(Edad_c) = \sin\left(\frac{Edad_c}{10}\right)$$

$$f_2(IMC_c) = \cos\left(\frac{IMC_c}{5}\right)$$

- Relación no lineal con curvatura compleja donde es considerando un polinomio de tercer grado:

$$f_1(Edad_c) = 0.0005 Edad_c^3 - 0.01 Edad_c^2$$

$$f_2(IMC_c) = 0.0008 IMC_c^3 - 0.02 IMC_c^2$$

De esta manera, p_i se define como para la relación lineal y para cada caso de relación no lineal teniendo en cuenta η_i , se define la función

$$p_i = \frac{1}{1 + \exp(-\beta_0 + \eta_i)}$$

3. Se consideran los modelos a comparar

- Regresión logística:

$$\log(p_i) = \log\left(\frac{p_i}{1 - p_i}\right) \quad (10)$$

- Modelo aditivo generalizado:

$$\log(p_i) = \alpha_0 + s_1(EDAD_i) + s_2(IMC_i) + \alpha_3 SEDE_i \quad (11)$$

4. Número de réplicas: $2 \times 3 \times 5 \times 4 = 120$ escenarios para un total de $100 \times 120 = 12000$ simulaciones.

3.8. Métricas de evaluación

- Área bajo la curva ROC (AUC): Es una medida utilizada para cuantificar la capacidad de un modelo de clasificación para discriminar entre dos clases (Amedenu et al., 2016). La curva ROC se construye a partir de la tasa de verdaderos positivos (sensibilidad) y la tasa de falsos

positivos (1 - especificidad) para diferentes puntos de corte del modelo.

En este sentido, el AUC resume el desempeño global del modelo a través de todos los posibles umbrales, y puede interpretarse como una medida que evalúa la capacidad de discriminación, es decir, su habilidad para distinguir entre las dos clases. Formalmente, se define como:

$$AUC = \int_0^1 TVP(TFP) d(TFP) \quad (12)$$

donde:

- TVP , es la tasa de verdaderos positivos.
 - TFP , es la tasa de falsos positivos.
- **AIC:** es una medida para seleccionar entre modelos estadísticos que equilibra la calidad del ajuste y la complejidad del modelo. Se basa en la verosimilitud e incluye una penalización por el número de parámetros, con el objetivo de evitar el sobreajuste que busca minimizar la pérdida de información. (Flood-Page et al., [2024](#)). Se define tal que

$$AIC = -2\log(L) + 2k \quad (13)$$

donde,

- L : Es la función de máxima verosimilitud del modelo.
 - k : Número de parámetros del modelo.
 - $\log(L)$: Log-verosimilitud.
- **ACC (Accuracy):** Permite la valoración de la relación entre variables predictoras métrica y múltiples medidas dependientes, lo que se traduce como la proporción de predicciones correctas sobre el total de las mismas (Badii et al., [2017](#)). Se define como

$$ACC = \frac{VP + VN}{VP + VN + FP + FN} \quad (14)$$

donde VP representa los verdaderos positivos, VN los verdaderos negativos, FP los falsos positivos y FN los falsos negativos.

- **Matriz de confusión:** es un cuadro que se utiliza para evaluar modelos de clasificación comparando las etiquetas de clase predichas con las reales (Shirdel et al., 2026)

	Predictivo Positivo	Predictivo Negativo
Actual Positivo	Verdadero Positivo (VP)	Falso Negativo (FN)
Actual Negativo	Falso Positivo (FP)	Verdadero Negativo (VN)

Las cantidades clave en la matriz de confusión son:

- **Verdadero Positivo (VP):** El modelo predice correctamente un resultado positivo.
- **Falso Negativo (FN):** El modelo predice un resultado negativo, pero el resultado real es positivo.
- **Falso Positivo (FP):** El modelo predice un resultado positivo, pero el resultado real es negativo.
- **Verdadero Negativo (VN):** El modelo predice correctamente un resultado negativo.

A partir de la matriz anterior se definen las siguientes métricas:

- **Sensibilidad (Recall):** Mide la proporción de casos positivos que son correctamente identificados por el modelo (Amedenu et al., 2016). Se define

$$sensibilidad = \frac{VP}{VP + FN} \quad (15)$$

- Especificidad: Se define como la proporción de negativos que se identifican correctamente como tales, o la probabilidad de un resultado negativo en la prueba. Esto también se conoce como tasa de verdaderos negativos (Amedenu et al., 2016).

$$especificidad = \frac{VN}{VN + FP} \quad (16)$$

- Precisión: Mide la proporción de predicciones positivas que son realmente positivas y se define

$$Precision = \frac{VP}{VP + FP} \quad (17)$$

- F1- Score: Corresponde a una media entre la precisión y la sensibilidad (Recall), proporcionando una medida balanceada del desempeño del modelo.

$$F_1 = \frac{VP}{VP + \frac{1}{2}FP + \frac{1}{2}FN} \quad (18)$$

- Balanced Accuracy: Promedia la sensibilidad y la especificidad definiendose

$$Balanced Accuracy = \frac{1}{2} \left(\frac{VP}{VP + FN} + \frac{VN}{VN + FP} \right) \quad (19)$$

4. Metodología

4.1. Tipo y diseño de investigación

La metodología del estudio se fundamenta en un enfoque cuantitativo y comparativo basado en procesos de simulación. Se definen distintos escenarios caracterizados por distintos niveles de desbalance en la variable respuesta y por estructuras no lineales conocidas entre la respuesta y al menos una covariable explicativa. Sobre cada conjunto de datos se ajustan modelos de regresión logística y modelos aditivos generalizados, con el fin de evaluar su comportamiento bajo condi-

ciones controladas (Aguilar Barreiro, 2019). El desempeño de los modelos se evaluará mediante medidas de ajuste global y métricas predictivas, lo que permitirá analizar cómo varía su comportamiento en función del grado de desbalance de la variable respuesta y de la presencia de relaciones no lineales entre las covariables y la probabilidad del evento de interés. En particular, se utilizará el criterio de información de Akaike (AIC), el cual permite comparar el ajuste relativo entre modelos al considerar simultáneamente la verosimilitud y la complejidad del modelo, penalizando aquellos con mayor número de parámetros. Por otra parte, se empleará el área bajo la curva ROC (AUC), que mide la capacidad de discriminación del modelo, es decir, su habilidad para distinguir correctamente entre las dos categorías de la variable respuesta, correspondientes a la presencia o ausencia de discapacidad. Adicionalmente, se considerarán métricas de clasificación como el *accuracy*, la *sensitivity* y la *specificity*, con el fin de evaluar el desempeño predictivo de los modelos en los distintos escenarios analizados. En conjunto, estas medidas permiten examinar tanto la calidad del ajuste como la capacidad de clasificación de los modelos bajo diferentes condiciones de simulación. De esta manera, el diseño metodológico propuesto facilita la comparación objetiva entre los enfoques considerados y garantiza la reproducibilidad de los resultados mediante la definición explícita de los escenarios de simulación y la generación de múltiples réplicas. Los escenarios de simulación se definirán variando algunas características relevantes de los datos, como el nivel de desbalance de la variable respuesta, la relación de no linealidad entre las covariables y la probabilidad del evento de interés y diferentes tamaños de muestra. Estas condiciones permitirán analizar el comportamiento de los modelos bajo diferentes contextos y evaluar en qué situaciones los modelos aditivos generalizados pueden presentar ventajas frente a la regresión logística tradicional. En este contexto, (Amedenu et al., 2025) emplearon conjuntos de datos simulados y un conjunto de datos real sobre cáncer de mama para comparar el desempeño de siete modelos de fragilidad dentro del marco de los modelos de tiempo de fallo acelerado. La evaluación se realizó mediante los criterios AIC y BIC bajo distintos escenarios, lo que permitió analizar el comportamiento de los modelos en diferentes contextos. Este enfoque metodológico respalda la utilidad de las simulaciones para comparar estrategias estadísticas, tal como se propone en el presente trabajo.

4.2. Población

La población de interés está conformada por las personas ingresadas en la E.S.E. Subred Integrada de Servicios de Salud Norte, Bogotá D.C.

4.3. Tipo de muestreo

Los datos corresponden a los registros disponibles en Datos Abiertos Colombia, proporcionados por la E.S.E. Subred Integrada de Servicios de Salud Norte, Bogotá D.C (E.S.E. Subred Integrada de Servicios de Salud Norte, Bogotá D.C., [2024](#)).

4.4. Variables

Inicialmente, la base de datos está conformada por 2525 registros, cada uno correspondiente a un paciente, y contiene un total de 28 variables. Estas se distribuyen en cuatro variables antropométricas, dos variables sociodemográficas, cuatro variables de identidad social, ocho variables clínicas y once variables de resultados clínicos. A partir de este conjunto, se seleccionaron las variables de interés para el presente estudio.

Cuadro 1: Variables de interés en el estudio


Variable	Descripción	Categoría / Rango
Discapacidad	Indica si la persona presenta una condición de discapacidad.	Sí / No
Edad	Edad en años de la persona.	19 – 98
IMC	Índice de masa corporal, calculado como peso (kg) dividido por la estatura al cuadrado (m ²).	15 – 53
Sede	Sede de atención correspondiente a la Subred Norte E.S.E.	Categórica (múltiples sedes 1)

5. Resultados

A continuación, se presentarán los resultados de las simulaciones realizadas. En primera instancia, se mostrarán las tendencias y distribuciones más determinantes utilizadas en la aplicación de este trabajo, con el fin de realizar un análisis descriptivo que permita identificar sus principales características y patrones de comportamiento antes de abordar el análisis comparativo de los modelos considerados.

5.1. Análisis de la variable edad

Figura 2: Distribución de la variable edad



Fuente: Elaboración propia

A partir de la figura anterior, se observa que la variable edad presenta una distribución centrada principalmente entre los 60 y 75 años, lo que indica una mayor presencia de personas pertenecientes al grupo de adulto mayor o tercera edad, categoría que, de acuerdo con (Departamento Administrativo Nacional de Estadística (DANE), [s. f.](#)), corresponde a individuos de 60 años o más. En base a esto, se analizaron las medidas de dispersión, las cuales confirman la información expuesta en la figura 2.

Cuadro 2: Medidas descriptivas de la variable Edad


Media	Mediana	D. Estándar	Mín	Máx
68.00238	69	12.97828	19	98

Cuadro 3: Percentiles de la variable Edad

0 %	25 %	50 %	75 %	100 %
19	61	69	77	98

5.2. Análisis de la variable sede

Figura 3: Distribución de la variable sede



Fuente: Elaboración propia


Se observa que la distribución de atenciones por sede destaca la Unidad de Servicios de Salud Ferias como la institución con mayor frecuencia de registros. Así mismo, se evidencia una disminución progresiva en el número de atenciones en las demás sedes. Además de, mostrar una presencia significativa de registros en el centro de salud tipo II San Cristóbal y Gaitana en comparación con las demás sedes. Este fuerte desbalance de clases en la variable sede podría repercutir

en la detección de los eventos ya que le daría efectos positivos o negativos a los modelos de tal manera que otorgaría mayor peso a las sedes predominantes y menor peso a las menos frecuentes.

5.3. Análisis de la variable IMC


El índice de masa corporal (IMC) se define como la relación entre el peso y el cuadrado de la talla según los valores propuestos por (Organización Mundial de la Salud, [2024](#)). En base a esto, los datos proporcionados nos arrojan características importantes, sobre todo en el tema de los percentiles ya que se puede observar una tendencia de sobrepeso.

Figura 4: Distribución de la variable IMC



Fuente: Elaboración propia

Figura 5: Boxplot de la variable IMC



Fuente: Elaboración propia


Cuadro 4: Medidas descriptivas de la variable IMC				
Media	Mediana	D. Estándar	Mín	Máx
26.99616	26.62	5.585999	15.06	53.41

Cuadro 5: Percentiles de la variable IMC				
0 %	25 %	50 %	75 %	100 %
15.06	23.44	26.62	30.08	53.41

Según las métricas y el análisis gráfico obtenido previamente, se evidencia una tendencia hacia el sobrepeso de acuerdo con los criterios de clasificación del índice de masa corporal (IMC) (Organización Mundial de la Salud, 2024). En consecuencia, esta variable se considera relevante, dado que podría influir en la discriminación entre individuos con y sin discapacidad.

5.4. Análisis de la variable discapacidad determinada por la edad

Figura 6: Distribución de la variable discapacidad determinada por la edad



Fuente: Elaboración propia

A partir de la figura previa, se observa que la variable discapacidad, analizada en función de la edad, presenta un comportamiento desbalanceado, evidenciado por una mayor proporción de individuos sin discapacidad en comparación con aquellos que la presentan, siendo estos últimos la clase minoritaria. Así mismo, se identifica una mayor concentración de casos de discapacidad en individuos de edades más avanzadas, mientras que la ausencia de esta se distribuye en menor proporción en personas más jóvenes. Este patrón sugiere que la edad podría constituirse como un factor relevante en la presencia o ausencia de discapacidad. Este comportamiento es consistente con estudios previos que reportan una mayor prevalencia de discapacidad en adultos mayores (Organización Mundial de la Salud & Banco Mundial, 2011). En este sentido, el análisis descriptivo realizado establece una base fundamental para el desarrollo de este estudio.

5.5. Análisis de los resultados de los datos reales

Por medio de los datos reales, se hizo el ajuste de los modelos logísticos y GAM comparando sus estimaciones.

Variable significativa del modelo logístico	Estimación	Error	P- Valor
Intercepto	-4.610e+00	9.797e-01	2.53e-06
EDAD	5.901e-02	7.673e-03	1.45e-14
IMC	-8.092e-02	1.669e-02	1.24e-06
SEDE: SEDECENTRO DE SALUD TIPO II GAITANA	-2.110e+00	8.501e-01	0.0131

Cuadro 6: Estimaciones del modelo logístico en la base de datos real

Variable significativa del GAM	Estimación	Error	P- Valor
Intercepto	-6.054e+00	2.940e+00	0.0395
SEDE: CENTRO DE SALUD TIPO II GAITANA	-1.836e+00	8.780e-01	0.0365

Cuadro 7: Estimaciones del GAM en la base de datos real

A partir de los cuadros anteriores, se observa que la clasificación de la variable sede, “Centro De Salud Tipo II Gaitana” fué significativa para ambos modelos. Por el contrario, las variables edad e IMC solo resultaron significativas para el modelo de regresión logística. Así mismo, procedemos a hacer una evaluación de las métricas de desempeño de cada modelo por medio de validación cruzada con el fin de evaluar el desempeño del modelo. El conjunto de entrenamiento se dividió en $k=5$ subconjuntos obteniendo como resultados las siguientes métricas.

Modelo	AUC	ACC	AIC
GLM	0.8814531	0.9089109	1017.3
GAM	0.9299991	0.9366337	934.0329

Cuadro 8: Comparación de modelos ajustados a la base de datos real

El cuadro anterior, nos muestra que el modelo GAM resulta superior que el modelo logístico en términos de AUC. Así mismo, haciendo la prueba formal *t.test* para pruebas pareadas se obtuvieron los siguientes resultados.

Valor t	p valor
t = -3.8446	0.01839

Cuadro 9: Prueba t, muestras pareadas en modelos con datos reales

De esta manera, los resultados evidencian una diferencia estadísticamente significativa con un $p < 0.05$, indicando que el modelo GAM presenta una mayor capacidad discriminativa en comparación con el modelo logístico, a diferencia de las demás métricas que presentan diferencias poco

significativas. Sin embargo, en las figuras de función suave de las variables edad e IMC (7)(8) indican que los efectos de las covariables son esencialmente lineales y poco pronunciados, lo que explica por qué el modelo GAM no logra mejorar el desempeño frente al modelo logístico, ya que no hay evidencia suficiente de relaciones no lineales que justifiquen su mayor flexibilidad.

5.6. Análisis de los resultados de las simulaciones

Las simulaciones realizadas permiten evaluar el comportamiento de la regresión logística clásica y los modelos aditivos generalizados (GAM) bajo diferentes escenarios de desbalance, tamaños de muestra, niveles de correlación y grados de no linealidad. En términos generales, los resultados muestran que el desempeño relativo de ambos enfoques depende principalmente de la complejidad de la relación entre las covariables y la respuesta.

5.6.1. Resultados de las métricas de desempeño en la relación lineal

Se exponen los resultados de las simulaciones evaluados en el modelo logístico y en el GAM bajo distintos niveles de correlación, desbalance y tamaños de muestra para la relación lineal.

A partir de los resultados presentados en los cuadros de las métricas de desempeño con un componente lineal (11) (16), se observa que cuando la relación entre las covariables y la variable respuesta es de naturaleza lineal, la regresión logística y el GAM presentan desempeños casi idénticos en sus métricas. Este comportamiento se sostiene para diferentes tamaños de muestra, niveles de desbalance y niveles de correlación. Lo anterior indica que, cuando el supuesto de linealidad se cumple, el modelo logístico clásico resulta suficiente para representar adecuadamente la estructura de los datos, por lo tanto, la flexibilidad del GAM no genera ventaja y puede resultar innecesaria.

5.6.2. Resultados de las métricas de desempeño en las relaciones NO lineales

A partir de los resultados presentados en los cuadros (14)(16)(18)(13)(15)(17), se observa que, a medida que aumenta la complejidad funcional de la relación entre las covariables y la respuesta, el GAM comienza a mostrar mejoras progresivas respecto a la regresión logística, ventajas que, son

especialmente evidentes en los escenarios de relaciones no lineales suaves y fuertes, donde el GAM obtiene mayores valores de AUC y menores valores de AIC, evidenciando una mejor capacidad de ajuste y discriminación.

Así mismo, los resultados muestran que la "magnitud" de la no linealidad consideradas en las simulaciones, influyen directamente sobre la diferencia entre ambos modelos. En relaciones no lineales débiles las diferencias son pequeñas, mientras que en relaciones suaves y fuertes las ventajas del GAM se vuelven considerablemente más evidentes. Esto sugiere que la utilidad de los modelos flexibles depende del grado de complejidad de la estructura funcional verdadera.

De igual manera, se observa que el desbalance de clases afecta el desempeño general de ambos modelos. Este resultado se logra a medida que disminuye la proporción de eventos positivos, donde se registra una reducción progresiva en indicadores como el AUC y la Accuracy. Sin embargo, los efectos del desbalance se acentúa más cuando se combinan con relaciones no lineales, escenario en el cual el GAM logra mantener un mejor desempeño predictivo que la regresión logística clásica.

Cuando se considera el tamaño de muestra, el cual desempeña un papel importante en el comportamiento del GAM. Se observa que, en muestras pequeñas las diferencias entre modelos suelen ser reducidas e incluso inestables. No obstante, a medida que aumenta el tamaño de muestra, las ventajas del GAM se vuelven más consistentes, particularmente en escenarios con relaciones no lineales complejas. Esto sugiere que los modelos GAM requieren suficiente información para estimar adecuadamente las funciones suaves. De igual manera, aunque se consideraron distintos niveles de correlación entre covariables, los resultados sugieren que la correlación tiene un efecto relativamente menor sobre las diferencias entre modelos. En comparación, la presencia de no linealidad produce efectos mucho más notorios sobre el desempeño predictivo y la calidad del ajuste.

Finalmente, en los escenarios no lineales, el GAM presenta consistentemente menores valores de AIC respecto a la regresión logística. Indicando que, además de mejorar la capacidad predictiva, el GAM logra representar de mejor manera la estructura generadora de los datos siempre y cuando cuente con información suficiente.

6. Resultados y conclusiones

Los resultados obtenidos a partir del ajuste de los modelos sobre la base de datos real y los datos simulados muestran que el modelo GAM presenta, en general, un mejor desempeño que el modelo logístico en escenarios donde el tamaño de muestra corresponde a $n = 600, 1000$. Así mismo, en términos de capacidad predictiva, el GAM alcanza un valor de AUC ligeramente superior en estos escenarios, lo que sugiere que tiene una mejor capacidad para distinguir correctamente entre las clases con suficiente información. Así mismo, la métrica de ACC también favorece al GAM, aunque la diferencia entre ambos modelos es pequeña. Sin embargo, la diferencia más importante se observa en el criterio AIC, donde el GAM obtiene un valor considerablemente menor que el modelo logístico. Esto es relevante porque un AIC más bajo indica un mejor balance entre la calidad del ajuste y la complejidad del modelo. En conjunto, estos resultados sugieren que el GAM logra representar de manera más adecuada las relaciones presentes en los datos, capturando posibles comportamientos no lineales sin perder capacidad predictiva cuando el tamaño de muestra es suficiente. De la misma manera, en los resultados de las simulaciones, se observa que la regresión logística mantiene un desempeño competitivo cuando la relación verdadera es lineal y con pocas observaciones, mientras que el GAM ofrece ventajas importantes en escenarios donde existen relaciones no lineales, especialmente cuando estas son suaves o complejas.

De igual manera, las métricas obtenidas a partir de la matriz de confusión, es decir, la sensibilidad (Recall), la precisión, F1-Score y Balanced Accuracy, muestran que el desempeño de los modelos depende en gran medida del desbalance de las clases. En particular, la sensibilidad toma valores bastante bajos cuando el evento es poco frecuente, lo que indica que los modelos tienen dificultades para identificar correctamente los casos de la clase minoritaria.

Aunque la precisión puede ser moderada en algunos escenarios, esto ocurre porque el modelo tiende a predecir pocos casos positivos, lo que reduce los errores pero también deja pasar muchos casos reales. Así mismo, el F1-score refleja que no hay un buen equilibrio entre detectar correctamente los positivos y evitar errores. Por su parte, la balanced accuracy se comporta de manera más estable, pero aun así muestra que el rendimiento general sigue siendo limitado cuando los datos

están desbalanceados. En conjunto, estos resultados sugieren que el principal problema no es tipo de modelo utilizado, sino en las características de los datos. Finalmente, los resultados resaltan que la flexibilidad del GAM puede representar una ventaja importante en contextos complejos; sin embargo, su utilidad depende tanto del tamaño de muestra como de la verdadera estructura funcional de los datos.

7. Anexos

1. La variable sede en la base de datos real, presenta los siguientes niveles:

Variable	Descripción	Categoría
Sede	Sede municipal de la clínica Subred Norte E.S.E	■ Centro de salud tipo I Buena-vista ■ Centro de salud tipo I San Luis ■ Centro de salud tipo II Bachué ■ Centro de salud tipo II Gaitana ■ Centro de salud tipo II Prado Veraniego ■ Centro de salud tipo II San Cristóbal ■ Centro de salud tipo II Suba ■ Centro de salud tipo II Verbenal ■ Hospital Chapinero ■ Hospital Emaús ■ Hospital Engativá Calle 80 ■ Hospital Simón Bolívar ■ Hospital Suba Centro de Servicios Especializados ■ Unidad de servicios de salud ferias

Cuadro 10: Categorías de la variable sede

2. cuadros de desempeño de los modelos logísticos y GAM clasificadas en componentes lineales y no lineales.

n	Correlación	Desbalance	AUC	ACC	AIC	Rec	Prec	F1	BalAcc
50	0.3	0.05	0.719	0.914	15.3	0.142	0.153	0.598	0.552
		0.15	0.746	0.816	28.7	0.244	0.381	0.487	0.583
		0.5	0.710	0.637	45.6	0.644	0.639	0.631	0.637
	0.8	0.05	0.681	0.913	15.1	0.149	0.144	0.574	0.550
		0.15	0.745	0.820	27.9	0.283	0.418	0.509	0.602
		0.5	0.734	0.655	43.7	0.666	0.684	0.652	0.659
100	0.3	0.05	0.725	0.934	27.3	0.0468	0.107	0.567	0.515
		0.15	0.703	0.832	53.5	0.145	0.411	0.349	0.553
		0.5	0.728	0.657	87.1	0.648	0.676	0.643	0.660
	0.8	0.05	0.648	0.931	26.0	0.0469	0.0991	0.553	0.514
		0.15	0.699	0.837	50.8	0.204	0.534	0.406	0.582
		0.5	0.739	0.681	83.4	0.680	0.696	0.673	0.684
300	0.3	0.05	0.738	0.954	78.5	0.0422	0.464	0.414	0.520
		0.15	0.755	0.854	157	0.118	0.538	0.261	0.550
		0.5	0.752	0.680	253	0.687	0.679	0.679	0.680
	0.8	0.05	0.767	0.952	74.6	0.0667	0.439	0.384	0.531
		0.15	0.787	0.856	150	0.175	0.589	0.286	0.575
		0.5	0.779	0.702	241	0.707	0.701	0.700	0.703
600	0.3	0.05	0.749	0.949	151	0.0151	0.440	0.188	0.507
		0.15	0.752	0.852	306	0.118	0.559	0.217	0.551
		0.5	0.744	0.680	496	0.685	0.684	0.683	0.680
	0.8	0.05	0.769	0.950	145	0.0344	0.594	0.222	0.516
		0.15	0.782	0.855	294	0.167	0.608	0.256	0.573
		0.5	0.775	0.704	472	0.707	0.709	0.706	0.704
1000	0.3	0.05	0.759	0.949	251	0.0124	0.468	0.132	0.506
		0.15	0.757	0.853	508	0.123	0.593	0.203	0.554
		0.5	0.750	0.684	825	0.687	0.685	0.685	0.685
	0.8	0.05	0.790	0.948	240	0.0239	0.406	0.152	0.511
		0.15	0.792	0.856	487	0.170	0.607	0.259	0.575
		0.5	0.779	0.709	788	0.714	0.709	0.710	0.709

Cuadro 11: Métricas de desempeño de modelo logístico: Componente LINEAL

n	Correlación	Desbalance	AUC	ACC	AIC	Rec	Prec	F1	BalAcc
50	0.3	0.05	0.647	0.888	12.7	0.156	0.125	0.541	0.547
		0.15	0.670	0.778	22.3	0.317	0.293	0.451	0.592
		0.5	0.659	0.597	37.9	0.608	0.602	0.583	0.601
	0.8	0.05	0.626	0.894	12.3	0.172	0.110	0.531	0.549
		0.15	0.667	0.793	21.7	0.305	0.329	0.494	0.593
		0.5	0.687	0.626	36.5	0.626	0.653	0.620	0.627
100	0.3	0.05	0.650	0.914	22.9	0.0916	0.0918	0.567	0.527
		0.15	0.683	0.818	49.7	0.171	0.331	0.343	0.555
		0.5	0.711	0.643	84.9	0.642	0.659	0.633	0.647
	0.8	0.05	0.723	0.916	21.4	0.0927	0.123	0.506	0.527
		0.15	0.704	0.818	47.4	0.202	0.410	0.381	0.570
		0.5	0.731	0.671	81.4	0.672	0.690	0.663	0.676
300	0.3	0.05	0.721	0.951	76.7	0.0417	0.191	0.313	0.518
		0.15	0.748	0.855	155	0.132	0.548	0.269	0.557
		0.5	0.746	0.678	251	0.685	0.676	0.676	0.678
	0.8	0.05	0.759	0.949	72.9	0.0567	0.275	0.331	0.525
		0.15	0.777	0.857	148	0.187	0.588	0.296	0.581
		0.5	0.772	0.697	240	0.701	0.698	0.695	0.699
600	0.3	0.05	0.738	0.948	149	0.0196	0.364	0.191	0.509
		0.15	0.749	0.851	304	0.114	0.545	0.204	0.548
		0.5	0.743	0.679	495	0.685	0.683	0.682	0.679
	0.8	0.05	0.760	0.949	144	0.0413	0.523	0.242	0.519
		0.15	0.779	0.854	292	0.166	0.591	0.253	0.572
		0.5	0.775	0.704	471	0.711	0.708	0.708	0.704
1000	0.3	0.05	0.752	0.949	249	0.0137	0.495	0.130	0.506
		0.15	0.756	0.852	507	0.126	0.587	0.205	0.554
		0.5	0.750	0.683	824	0.685	0.684	0.683	0.683
	0.8	0.05	0.788	0.948	239	0.0243	0.391	0.155	0.511
		0.15	0.790	0.857	485	0.168	0.619	0.258	0.574
		0.5	0.778	0.707	786	0.710	0.708	0.708	0.707

Cuadro 12: Métricas de desempeño de GAM: Componente LINEAL

n	Correlación	Desbalance	AUC	ACC	AIC	Rec	Prec	F1	BalAcc
50	0.3	0.05	0.683	0.921	18.7	0.0254	0.05	0.583	0.499
		0.15	0.668	0.818	34.1	0.0348	0.141	0.450	0.496
		0.5	0.645	0.561	51.1	0.537	0.582	0.528	0.566
	0.8	0.05	0.683	0.921	18.2	0.0175	0.0238	0.667	0.495
		0.15	0.671	0.819	33.5	0.0516	0.189	0.442	0.502
		0.5	0.647	0.579	50.6	0.567	0.594	0.560	0.585
100	0.3	0.05	0.705	0.949	31.7	0.0132	0.0385	0.667	0.503
		0.15	0.641	0.845	64.1	0.0119	0.181	0.293	0.501
		0.5	0.635	0.845	97.1	0.557	0.586	0.553	0.583
	0.8	0.05	0.691	0.949	30.7	0.0133	0.0625	1	0.503
		0.15	0.655	0.849	63.6	0.0241	0.276	0.358	0.506
		0.5	0.640	0.598	96.8	0.570	0.611	0.568	0.599
300	0.3	0.05	0.641	0.952	88.8	0.002	1	0.333	0.501
		0.15	0.618	0.852	178	0.00394	0.256	0.137	0.501
		0.5	0.636	0.594	281	0.591	0.603	0.589	0.594
	0.8	0.05	0.630	0.949	88.9	0	NaN	NaN	0.5
		0.15	0.630	0.849	177	0.00136	0.143	0.127	0.500
		0.5	0.656	0.613	278	0.629	0.615	0.616	0.613
600	0.3	0.05	0.623	0.947	171	0	0	NaN	0.500
		0.15	0.634	0.845	349	0.000370	0.0208	0.0645	0.499
		0.5	0.643	0.604	558	0.592	0.602	0.593	0.604
	0.8	0.05	0.615	0.947	170	0	NaN	NaN	0.5
		0.15	0.631	0.844	349	0.000792	0.0833	0.0707	0.500
		0.5	0.664	0.622	553	0.617	0.615	0.613	0.622
1000	0.3	0.05	0.621	0.951	279	0	NaN	NaN	0.5
		0.15	0.633	0.848	577	0.000709	0.135	0.0439	0.500
		0.5	0.652	0.611	924	0.606	0.609	0.605	0.611
	0.8	0.05	0.630	0.950	277	0	NaN	NaN	0.5
		0.15	0.635	0.848	577	0.000638	0.229	0.0409	0.500
		0.5	0.669	0.627	919	0.628	0.621	0.623	0.627

Cuadro 13: Métricas de desempeño de modelo logístico: Componente NO LINEAL DÉBIL

n	Correlación	Desbalance	AUC	ACC	AIC	Rec	Prec	F1	BalAcc
50	0.3	0.05	0.589	0.877	13.6	0.144	0.0869	0.569	0.533
		0.15	0.660	0.759	25.4	0.183	0.180	0.435	0.518
		0.5	0.651	0.581	40.5	0.593	0.606	0.566	0.594
	0.8	0.05	0.675	0.891	14.2	0.173	0.136	0.624	0.553
		0.15	0.652	0.778	27.2	0.179	0.202	0.450	0.530
		0.5	0.663	0.592	41.5	0.592	0.606	0.577	0.592
100	0.3	0.05	0.624	0.924	24.9	0.0329	0.0211	0.444	0.500
		0.15	0.635	0.810	57.2	0.0755	0.162	0.307	0.506
		0.5	0.660	0.609	89.7	0.625	0.609	0.602	0.612
	0.8	0.05	0.629	0.928	24.2	0.0511	0.0659	0.583	0.514
		0.15	0.645	0.819	56.4	0.0820	0.220	0.303	0.512
		0.5	0.680	0.632	88.3	0.662	0.636	0.633	0.633
300	0.3	0.05	0.639	0.950	84.9	0.00533	0.121	0.333	0.502
		0.15	0.645	0.851	171	0.0117	0.307	0.160	0.503
		0.5	0.685	0.634	262	0.695	0.627	0.654	0.633
	0.8	0.05	0.653	0.947	84.6	0.00404	0.139	0.278	0.501
		0.15	0.656	0.848	169	0.00796	0.304	0.143	0.502
		0.5	0.702	0.650	257	0.743	0.631	0.679	0.649
600	0.3	0.05	0.645	0.947	165	0	0	NaN	0.500
		0.15	0.676	0.845	335	0.00328	0.272	0.0847	0.501
		0.5	0.700	0.647	521	0.713	0.627	0.665	0.649
	0.8	0.05	0.645	0.947	163	0	0	NaN	0.500
		0.15	0.682	0.844	332	0.00315	0.528	0.0811	0.501
		0.5	0.715	0.658	509	0.754	0.628	0.683	0.660
1000	0.3	0.05	0.648	0.951	271	0	NaN	NaN	0.5
		0.15	0.676	0.848	554	0.000631	0.375	0.0406	0.500
		0.5	0.708	0.651	865	0.728	0.629	0.673	0.652
	0.8	0.05	0.669	0.950	269	0	0	NaN	0.500
		0.15	0.682	0.848	551	0.000848	0.167	0.0764	0.500
		0.5	0.723	0.664	850	0.767	0.631	0.691	0.665

Cuadro 14: Métricas de desempeño de GAM: Componente NO LINEAL DÉBIL

n	Correlación	Desbalance	AUC	ACC	AIC	Rec	Prec	F1	BalAcc
50	0.3	0.05	0.718	0.924	18.9	0.0439	0.0965	0.689	0.514
		0.15	0.687	0.822	32.7	0.0915	0.189	0.661	0.519
		0.5	0.662	0.562	50.3	0.592	0.587	0.553	0.566
	0.8	0.05	0.685	0.922	18.3	0.0278	0.533	0.667	0.503
		0.15	0.673	0.817	33.6	0.0389	0.417	0.442	0.493
		0.5	0.660	0.57	50.3	0.570	0.550	0.560	0.581
100	0.3	0.05	0.722	0.948	31.7	0.0130	0.0385	0.667	0.503
		0.15	0.673	0.842	61.6	0.0447	0.308	0.394	0.513
		0.5	0.628	0.6	96.9	0.593	0.601	0.579	0.601
	0.8	0.05	0.724	0.949	31.2	0.0132	0.0588	1	0.503
		0.15	0.667	0.848	62.2	0.0460	0.344	0.396	0.516
		0.5	0.650	0.604	96.0	0.618	0.604	0.594	0.608
300	0.3	0.05	0.661	0.952	85.5	0.00174	0.25	0.286	0.501
		0.15	0.653	0.851	178	0.0105	0.323	0.140	0.503
		0.5	0.655	0.617	278	0.619	0.626	0.615	0.618
	0.8	0.05	0.646	0.951	87.1	0.00255	0.5	0.4	0.501
		0.15	0.645	0.850	174	0.0109	0.337	0.159	0.504
		0.5	0.659	0.617	278	0.625	0.622	0.616	0.618
600	0.3	0.05	0.657	0.946	166	0	NaN	NaN	0.5
		0.15	0.670	0.844	343	0.00585	0.207	0.0709	0.501
		0.5	0.663	0.627	552	0.626	0.621	0.620	0.627
	0.8	0.05	0.640	0.947	167	0	NaN	NaN	0.5
		0.15	0.660	0.846	346	0.00272	0.151	0.0695	0.500
		0.5	0.664	0.625	554	0.622	0.621	0.618	0.626
1000	0.3	0.05	0.664	0.951	271	0	NaN	NaN	0.5
		0.15	0.673	0.846	568	0.00416	0.217	0.0543	0.501
		0.5	0.668	0.630	917	0.626	0.627	0.624	0.630
	0.8	0.05	0.648	0.951	272	0.000556	1	0.105	0.500
		0.15	0.665	0.846	571	0.00325	0.292	0.0504	0.501
		0.5	0.667	0.630	917	0.631	0.624	0.625	0.630

Cuadro 15: Métricas de desempeño de modelo logístico: Componente NO LINEAL SUAVE

n	Correlación	Desbalance	AUC	ACC	AIC	Rec	Prec	F1	BalAcc
50	0.3	0.05	0.646	0.881	14.2	0.149	0.108	0.662	0.541
		0.15	0.625	0.784	24.5	0.183	0.201	0.471	0.531
		0.5	0.657	0.583	40.9	0.627	0.594	0.584	0.591
	0.8	0.05	0.631	0.889	14.2	0.198	0.144	0.649	0.565
		0.15	0.640	0.779	26.6	0.184	0.169	0.428	0.529
		0.5	0.660	0.577	41.1	0.603	0.595	0.574	0.584
100	0.3	0.05	0.624	0.927	25.0	0.0455	0.0578	0.522	0.509
		0.15	0.648	0.807	53.7	0.121	0.208	0.305	0.526
		0.5	0.649	0.609	89.2	0.617	0.604	0.598	0.610
	0.8	0.05	0.656	0.926	24.5	0.0746	0.0891	0.542	0.521
		0.15	0.646	0.81	53.4	0.102	0.229	0.316	0.517
		0.5	0.667	0.621	90.1	0.648	0.613	0.614	0.625
300	0.3	0.05	0.681	0.949	80.5	0.00521	0.1	0.343	0.500
		0.15	0.673	0.847	166	0.0276	0.294	0.179	0.508
		0.5	0.699	0.643	261	0.656	0.650	0.647	0.644
	0.8	0.05	0.654	0.948	82.2	0.0128	0.147	0.340	0.505
		0.15	0.673	0.847	166	0.0151	0.233	0.187	0.504
		0.5	0.701	0.647	262	0.687	0.643	0.660	0.648
600	0.3	0.05	0.669	0.945	158	0	0	NaN	0.500
		0.15	0.702	0.843	328	0.0186	0.302	0.105	0.506
		0.5	0.710	0.652	521	0.651	0.646	0.645	0.652
	0.8	0.05	0.653	0.947	159	0.00233	0.153	0.186	0.501
		0.15	0.699	0.846	330	0.0126	0.363	0.109	0.504
		0.5	0.709	0.653	522	0.690	0.639	0.661	0.654
1000	0.3	0.05	0.695	0.951	262	0.000625	0.25	0.118	0.500
		0.15	0.716	0.848	542	0.0154	0.426	0.104	0.506
		0.5	0.718	0.661	866	0.665	0.656	0.659	0.661
	0.8	0.05	0.672	0.951	263	0.000833	0.333	0.154	0.500
		0.15	0.708	0.846	546	0.00797	0.342	0.0877	0.503
		0.5	0.719	0.661	865	0.699	0.644	0.669	0.661

Cuadro 16: Métricas de desempeño de GAM: componente NO LINEAL SUAVE


n	Correlación	Desbalance	AUC	ACC	AIC	Rec	Prec	F1	BalAcc
50	0.3	0.05	0.701	0.925	18.6	0.0481	0.0769	0.722	0.514
		0.15	0.662	0.823	32.5	0.0483	0.0680	0.384	0.519
		0.5	0.680	0.598	47.7	0.601	0.599	0.586	0.566
	0.8	0.05	0.685	0.923	18.3	0.0157	0.0714	0.667	0.5
		0.15	0.667	0.833	33.3	0.0543	0.160	0.442	0.526
		0.5	0.677	0.584	47.9	0.561	0.592	0.560	0.561
100	0.3	0.05	0.694	0.950	31.1	0.0540	0.193	0.683	0.523
		0.15	0.650	0.835	61.2	0.0505	0.370	0.413	0.516
		0.5	0.698	0.636	91.1	0.618	0.653	0.618	0.640
	0.8	0.05	0.698	0.947	30.9	0.0422	0.131	0.633	0.517
		0.15	0.623	0.84	62.1	0.0220	0.184	0.342	0.502
		0.5	0.682	0.619	92.1	0.606	0.631	0.600	0.622
300	0.3	0.05	0.700	0.952	80.4	0.0139	0.5	0.359	0.507
		0.15	0.662	0.855	171	0.0368	0.491	0.181	0.514
		0.5	0.709	0.641	262	0.635	0.653	0.637	0.643
	0.8	0.05	0.656	0.953	82.9	0.00255	0.333	0.4	0.501
		0.15	0.649	0.852	174	0.0187	0.381	0.202	0.507
		0.5	0.700	0.640	265	0.642	0.649	0.639	0.642
600	0.3	0.05	0.701	0.948	159	0.00689	0.667	0.205	0.503
		0.15	0.687	0.852	335	0.0371	0.736	0.126	0.517
		0.5	0.707	0.637	552	0.632	0.636	0.632	0.637
	0.8	0.05	0.665	0.948	163	0.000909	1	0.167	0.500
		0.15	0.658	0.848	343	0.0132	0.644	0.0933	0.506
		0.5	0.694	0.628	529	0.619	0.626	0.620	0.629
1000	0.3	0.05	0.708	0.951	259	0.00490	0.938	0.201	0.502
		0.15	0.680	0.852	555	0.0251	0.767	0.0875	0.512
		0.5	0.717	0.648	865	0.647	0.644	0.644	0.648
	0.8	0.05	0.680	0.950	267	0.000588	1	0.111	0.500
		0.15	0.653	0.851	563	0.0121	0.812	0.0773	0.506
		0.5	0.703	0.638	880	0.629	0.642	0.633	0.638

Cuadro 17: Métricas de desempeño de modelo logístico: Componente NO LINEAL FUERTE

n	Correlación	Desbalance	AUC	ACC	AIC	Rec	Prec	F1	BalAcc
50	0.3	0.05	0.639	0.883	13.2	0.170	0.105	0.579	0.540
		0.15	0.655	0.772	23.0	0.242	0.182	0.469	0.547
		0.5	0.694	0.619	34.3	0.625	0.614	0.605	0.619
	0.8	0.05	0.638	0.889	14.4	0.143	0.118	0.58	0.536
		0.15	0.645	0.773	24.3	0.193	0.170	0.450	0.528
		0.5	0.696	0.614	34.2	0.625	0.616	0.601	0.617
100	0.3	0.05	0.629	0.922	22.0	0.108	0.0915	0.518	0.534
		0.15	0.639	0.812	50.4	0.148	0.310	0.352	0.542
		0.5	0.749	0.690	78.5	0.747	0.675	0.698	0.693
	0.8	0.05	0.625	0.919	22.8	0.12	0.142	0.631	0.543
		0.15	0.658	0.819	51.8	0.117	0.266	0.325	0.528
		0.5	0.736	0.664	80.1	0.731	0.653	0.676	0.666
300	0.3	0.05	0.712	0.947	70.7	0.0949	0.408	0.375	0.543
		0.15	0.725	0.858	155	0.119	0.609	0.224	0.550
		0.5	0.782	0.710	223	0.789	0.687	0.731	0.709
	0.8	0.05	0.667	0.946	74.8	0.0340	0.192	0.307	0.512
		0.15	0.705	0.853	159	0.0768	0.586	0.200	0.532
		0.5	0.765	0.698	228	0.798	0.672	0.726	0.698
600	0.3	0.05	0.744	0.950	144	0.109	0.643	0.298	0.553
		0.15	0.758	0.858	303	0.103	0.716	0.191	0.548
		0.5	0.792	0.722	441	0.817	0.685	0.744	0.723
	0.8	0.05	0.713	0.949	150	0.0616	0.641	0.240	0.530
		0.15	0.728	0.851	315	0.0658	0.643	0.155	0.530
		0.5	0.778	0.707	450	0.817	0.667	0.732	0.709
1000	0.3	0.05	0.768	0.955	237	0.159	0.751	0.270	0.578
		0.15	0.754	0.860	501	0.107	0.755	0.187	0.550
		0.5	0.800	0.728	732	0.833	0.686	0.752	0.729
	0.8	0.05	0.733	0.951	248	0.0841	0.615	0.211	0.541
		0.15	0.734	0.857	514	0.0772	0.736	0.143	0.536
		0.5	0.783	0.714	748	0.826	0.676	0.743	0.714


Cuadro 18: Métricas de desempeño de GAM: Componente NO LINEAL FUERTE

Figura 7: Función suave para la variable Edad



Fuente: Elaboración propia

Figura 8: Función suave para la variable IMC



Fuente: Elaboración propia

8. Referencias

- Agresti, A. (2002). *Categorical Data Analysis* (2.^a ed.). John Wiley & Sons.
- Aguilar Barreiro, P. (2019). *Modelos aditivos generalizados* [Trabajo de grado]. Universidad de Sevilla.
- Amedenu, B. S., Ayitey, E., Ayiah Mensah, F., & Asare, L. (2016). ROC-ing along: Evaluation and interpretation of receiver operating characteristic curves. *Surgery*, 159(6), 1638-1645. <https://doi.org/10.1016/j.surg.2015.12.029>
- Amedenu, B. S., Ayitey, E., Ayiah Mensah, F., & Asare, L. (2025). Evaluating key predictors of breast cancer through survival: a comparison of AFT frailty models with LASSO, ridge, and elastic net regularization. *BMC Cancer*, 25(1), 665. <https://doi.org/10.1186/s12885-025-14040-z>
- Austin, P. C., Lee, J. V., & Douglas, S. (2010). Logistic regression had superior performance compared with regression trees for predicting in-hospital mortality in patients hospitalized with heart failure. *Journal of Clinical Epidemiology*, 63(10), 1145-1155. <https://doi.org/10.1016/j.jclinepi.2009.12.004>
- Awe, O. O., Olaniyan, O. A., Olatunde, A. E., Sewpaul, R., & Dukhi, N. (2025). A comparative analysis of generalized additive models for obesity risk prediction. *Healthcare Analytics*, 8(1). <https://doi.org/10.1016/j.health.2025.100410>
- Badii, M. H., Castillo, J., Cortez, A., Wong, K., & Villalpando, P. (2017). Canonical correlation analysis and scientific research. *Universidad Autónoma de Nuevo León (UANL)*, 2, 405-422.
- Chiabudini, M., Schumacher, M., & Graf, E. (2020). Comparison of complex modeling strategies for prediction of a binary outcome based on a few highly correlated predictors. *Biometrical Journal*, 62(3), 568-582. <https://doi.org/10.1002/bimj.201800243>
- Cho, S. J., Brown-Schmidt, S., De Boeck, P., & Naveiras, M. (2022). Space-time modeling of intensive binary time series eye-tracking data using a generalized additive logistic regression model. *Psychological Methods*, 27(3), 307-346. <https://doi.org/10.1037/met0000444>

- Departamento Administrativo Nacional de Estadística (DANE). (s. f.). Distribución de la población por grupos de edad. Consultado el 5 de junio de 2026, desde https://geoportal.dane.gov.co/servicios/atlas-estadistico/src/Tomo_I_Demografico/3.2.-distribucion-de-la-poblacion-por-grupos-de-edad.html
- Dobson, A. J. (2002). *An Introduction to Generalized Linear Models*. Chapman & Hall/CRC.
- E.S.E. Subred Integrada de Servicios de Salud Norte, Bogotá D.C. (2024). *Datos Abiertos Colombia*. Consultado el 3 de junio de 2026, desde https://www.datos.gov.co/Salud-y-Proteccion-Social/Enfermedades-Cronicas/2uxx-gxp3/about_data
- Flood-Page, G., Boutonnier, L., & Pereira, J.-M. (2024). Application of the Akaike Information Criterion to the interpretation of bender element tests. *Soil Dynamics and Earthquake Engineering*, 177, 108373. <https://doi.org/10.1016/j.soildyn.2023.108373>
- Ganev, K. (2000). Long-term trends of symptoms and disability in schizophrenia and related disorders. *Social Psychiatry and Psychiatric Epidemiology*, 35(9), 389-395. <https://www.proquest.com/scholarly-journals/long-term-trends-symptoms-disability/docview/236127293/se-2>
- Giolo, S. R. (2017). *Introdução à análise de dados categóricos com aplicações* (4.^a ed.). Edgard Blücher Ltda.
- Gómez, F., Osorio García, D., Panesso, L., & Curcio, C. L. (2021). Determinantes del envejecimiento saludable y la discapacidad en adultos mayores: SABE Colombia. *Revista Panamericana de Salud Pública*, 45(1), 45-98. <https://doi.org/10.26633/RPSP.2021.98>
- Hastie, T., & Tibshirani, R. (1990). *Generalized Additive Models*. Chapman & Hall.
- López, A. J. M. (2022). Epidemiología y factores asociados en personas con discapacidad de origen vial en Medellín (2004–2017). *Revista Salud UIS*, 54(1), e22033. <https://doi.org/10.18273/saluduis.54.e22033>
- Martínez Pérez, J., & Pérez Martín, P. (2024). Regresión logística. *Medicina de Familia. SEMERGEN*, 50(1), 123-135. <https://doi.org/10.1016/j.semerg.2023.102086>
- McCullagh, P., & Nelder, J. A. (1989). *Generalized Linear Models* (2.^a ed.). Chapman & Hall.

- Montgomery, D. C., Peck, E. A., & Vining, G. G. (2002). *Introducción al análisis de regresión lineal* (3.^a ed.) [Traducción de: Introduction to Linear Regression Analysis]. Compañía Editorial Continental (CECSA). <https://doi.org/10.1002/9781118625590>
- Muchlinski, D., Siroky, D. S., He, J., & Kocher, M. (2016). Comparación de bosques aleatorios y regresión logística para predecir datos desbalanceados: aplicación al inicio de la guerra civil. *Political Analysis*, 24(1), 87-103. <https://doi.org/10.1093/pan/mpv024>
- Muchlinski, D., Siroky, D. S., He, J., & Kocher, M. (2019). Statistical methodology for multiclass classifications: applications to dementia. *Journal of Alzheimer's Disease*, 68(1), 173-186. <https://doi.org/10.3233/JAD-180580>
- Organización Mundial de la Salud. (2024). Índice de masa corporal (IMC). Consultado el 5 de junio de 2026, desde <https://www.who.int/es>
- Organización Mundial de la Salud & Banco Mundial. (2011). *Informe mundial sobre la discapacidad*. Organización Mundial de la Salud. Consultado el 1 de enero de 2026, desde <https://www.who.int/es/publications/i/item/9789241564182>
- Organización Panamericana de la Salud. (2023). Discapacidad. Consultado el 1 de enero de 2026, desde <https://www.paho.org/es/temas/discapacidad>
- Saavedra, S. G. F. (2017). *Modelos de regresión logística aplicados al estudio de transmisión genética* [Tesis de pregrado]. Universidad Nacional Autónoma de México. Consultado el 1 de enero de 2026, desde <https://ru.dgb.unam.mx/server/api/core/bitstreams/f36a915e-3434-471d-9742-360ed3993e9f/content>
- Salazar, D. A., Vélez, J. I., & Salazar, J. C. (2012). Comparison between SVM and logistic regression: which one is better to discriminate? *Revista Colombiana de Estadística*, 35(2), 223-237. <http://www.redalyc.org/articulo.oa?id=89923144003>
- Shirdel, M., Di Mauro, M., & Liotta, A. (2026). A framework for binary classification evaluation metrics. *Information Sciences*, 749, 123540. <https://doi.org/https://doi.org/10.1016/j.ins.2026.123540>

- Woo, M.-J., Reiter, J. P., & Karr, A. F. (2008). Estimation of propensity scores using generalized additive models. *Statistics in Medicine*, 27(19), 3805-3816. <https://doi.org/10.1002/sim.3278>
- Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R* (2.^a ed.). Chapman; Hall/CRC. <https://doi.org/10.1201/9781315370279>
- Yeganeh, A., Johannssen, A., Chukhrova, N., Erfanian, M., Azarpazhooh, M. R., & Morovatdar, N. (2023). Un marco de seguimiento de los procesos de atención sanitaria mediante modelos aditivos generalizados y autoencoders. *Artificial Intelligence in Medicine*, 146(1). <https://doi.org/10.1016/j.artmed.2023.102689>